

AI/BigData 인텐시브 과정

강사장철원







장철원



- ❑ 마도학자 주식회사 대표이사
- ❑ 전) 나노쿠키 대표
- ❑ 전) NHN IT 보안실
- ❑ 전) 크래프톤 데이터 분석실

- ❑ 플로리다 주립대학교 통계학 박사과정 휴학
- ❑ 고려대학교 통계학 석사
- ❑ 충북대학교 통계학 학사

Section 강사소개



- 교보문고 이달의 책 선정
- 리디북스 주간베스트 1위
- yes24 컴퓨터공학 Top 100 12주

- 리디북스 주간베스트 2위
- yes24 IT/모바일 Top 100 1주

- 2021 교보문고 올해의 책 IT 전문서 3위
- 2021 교보문고 상반기 베스트셀러
- 리디북스 월간베스트 2위
- yes24 IT/모바일 Top 100 6주

- 2026 신간 도서

- 세종학술도서 2024
- yes24 IT/모바일 Top 100 18주
- yes24 네트워크/해킹보안 분야 2위
- yes24 쿠버네티스 도서 판매순위 1위

- 2022 교보문고 IT도서 Top 100
- yes24 프로그래밍언어 Top 100 4주




- 이상 탐지 모델 개발
- 게임 내부 알고리즘 변경



- 유저 이탈 예측 모델 개발
- 게임 로그 데이터 분석
- 매출 로그 데이터 분석




- 이상 거래 탐지 시스템 개발




- 대량 로그인 공격 방어 시스템
- 매크로 탐지 시스템 개발

Section 강사소개


회사 홈페이지: <https://www.madohakja.com>




유튜브: 장철원 머신러닝



기술블로그: <https://losskatsu.github.io>



링크드인: <https://www.linkedin.com/in/cheolwon-jang/>



Section
코스소개

DAY1

머신러닝
기초 개념

DAY2

지도학습

DAY3

DAY4

서비스
개발

DAY5

앙상블 학습

DAY6

비지도학습

DAY7

시계열분석

DAY8

DAY9

프로젝트

DAY10

□ 머신러닝 기초 개념

□ 머신러닝 학습 개념

□ 머신러닝 파이프라인

AI/BigData 인텐시브 과정

Section 1. 머신러닝 기초 개념

Section 1-1. 인공지능의 종류

인공지능?



인공지능의 종류

약인공지능(weak AI)




강인공지능(strong AI)



초인공지능(super AI)



인공지능의 종류




AI/BigData 인텐시브 과정


Section 1. 머신러닝 기초 개념

Section 1-2. 머신러닝 학습 개념


머신러닝




지도 학습
(supervised learning)




비지도 학습
(unsupervised learning)



지도 학습





비지도학습



학습




비지도학습 알고리즘



강화학습



Agent



Environment

Section
머신러닝 학습개념

지도학습(supervised learning)

피쳐(feature)			타겟(target)
색깔	꽃길이	가시유무	꽃이름
빨강	10	유	장미
노랑	40	무	해바라기
분홍	15	유	장미
보라	6	무	코스모스
빨강	7	무	tulip
분홍	7	무	코스모스

색깔	꽃길이	가시유무
빨강	12	무

비지도학습(unsupervised learning)

피쳐(feature)		
색깔	꽃길이	가시유무
빨강	10	유
노랑	40	무
분홍	15	유
보라	6	무
빨강	7	무
분홍	7	무

꽃이름
?

타겟 구성 요소 개수

x1	x2	...	x20	y
		...		1
		...		1
		...		1
		...		1
		...		1
		...		0
		...		0
		...		0
		...		0
		...		0

불량

양품

$$\text{우연히 맞출 확률} = \frac{2}{4} = 50\%$$

		예측	
		불량	양품
실제	불량	정답	오답
	양품	오답	정답


$$\text{우연히 맞출 확률} = \frac{1}{10} = 10\%$$
[illegible]

데이터 불균형(data imbalancing)

x1	x2	...	x20	y
		...		1
		...		0
		...		0
		...		0
		...		0
		...		0
		...		0
		...		0
		...		0
		...		0

} 불량

} 양품




대부분 양품으로 예측

데이터 불균형(data imbalancing)

x1	x2	...	x20	y
		...		1
		...		0
		...		0
		...		0
		...		0
		...		0
		...		0
		...		0
		...		0
		...		0

제품량

양품



x1	x2	...	x20	y
		...		1
		...		0


over sampling

오버샘플링은 비추천


x1	x2	...	x20	y
		...		1
		...		0
		...		0
		...		0
		...		0
		...		0
		...		0
		...		0
		...		0
		...		0
		...		0

} 불량

} 양품




x1	x2	...	x20	y
		...		1
		...		1
		...		1
		...		1
		...		1
		...		1
		...		1
		...		1
		...		1
		...		0
		...		0
		...		0
		...		0
		...		0
		...		0
		...		0
		...		0
		...		0
		...		0
		...		0



사실상 동일 샘플 복사

문자 -> 숫자 변환

x1	x2	x3	y
빨강	10	유	장미
노랑	40	무	해바라기
분홍	15	유	장미
보라	6	무	코스모스
빨강	7	무	tulip




x1	x2	x3	y
1	10	1	1
2	40	0	2
3	15	1	1
4	6	0	3
1	7	0	4

one hot encoding

타겟 데이터는 원핫 인코딩하지 않음

과일
사과
배
포도



과일 1	과일 2	과일3
1	0	0
0	1	0
0	0	1

one hot encoding

```
In [1]: ▶ 1 import numpy as np  
2 import pandas as pd
```

```
In [4]: ▶ 1 df = pd.DataFrame([  
2     [42, 'male', 12, 'reading', 1],  
3     [35, 'female', 3, 'cooking', 0],  
4     [27, 'female', 7, 'cycling', 2],  
5     [56, 'male', 21, 'swimming', 0]  
6 ])   
7   
8 df.columns=['age',  
9             'gender',  
10            'month_birth',  
11            'hobby',  
12            'target']
```

```
In [5]: ▶ 1 df
```

Out[5]:

	age	gender	month_birth	hobby	target
0	42	male	12	reading	1
1	35	female	3	cooking	0
2	27	female	7	cycling	2
3	56	male	21	swimming	0

one hot encoding

```
In [12]: 1 df_oh = pd.get_dummies(df, dtype=float)
```

```
In [13]: 1 df_oh
```

Out[13]:

	age	month_birth	target	gender_female	gender_male	hobby_cooking	hobby_cycling	hobby_reading	hobby_swimming
0	42	12	1	0.0	1.0	0.0	0.0	1.0	0.0
1	35	3	0	1.0	0.0	1.0	0.0	0.0	0.0
2	27	7	2	1.0	0.0	0.0	1.0	0.0	0.0
3	56	21	0	0.0	1.0	0.0	0.0	0.0	1.0

```
In [18]: 1 pd.get_dummies(df['hobby'], dtype=float)
```


Out[18]:

	cooking	cycling	reading	swimming
0	0.0	0.0	1.0	0.0
1	1.0	0.0	0.0	0.0
2	0.0	1.0	0.0	0.0
3	0.0	0.0	0.0	1.0

피처 엔지니어링(feature engineering) ?

?

수학 점수	영어 점수	y
90	94	1
80	78	1
75	88	1
64	84	1
58	60	1
88	85	0
77	70	0
82	90	0
92	95	0
95	95	0



피처가 2개밖에 없으니 기존
피처를 활용해 늘리자?

수학 점수	영어 점수	수학+영어	y
90	94	184	1
80	78	158	1
75	88	163	1
64	84	148	1
58	60	118	1
88	85	173	0
77	70	147	0
82	90	172	0
92	95	187	0
95	95	190	0


지도학습
(supervised learning)

회귀분석
로지스틱 회귀분석
의사결정나무
랜덤포레스트
서포트 벡터 머신
...

비지도학습
(unsupervised learning)

주성분 분석
계층 클러스터링
K-평균 클러스터링
...

인공지능으로 할 수 있는 것




색깔	꽃길이	가시유무	꽃이름
빨강	10	유	장미
노랑	40	무	해바라기
분홍	15	유	장미
보라	6	무	코스모스
빨강	7	무	tulip



색깔	꽃길이	가시유무	꽃길이
빨강	장미	유	10
노랑	해바라기	무	40
분홍	장미	유	15
보라	코스모스	무	6
빨강	tulip	무	7

데이터 품질의 중요성



데이터 품질 ↑ → 학습 ↑


데이터 품질 ↓ → 학습 ↓

데이터 품질의 중요성

전화번호	상품번호	사업자주소	판매량
010-1234-5378	3443	서울	100
010-1534-1678	6135	경기	200
010-6234-0678	1345	충북	300
010-9234-5078	1561	부산	250
010-1224-5670	7342	강원	150



색깔	가격	종류	판매량
노랑	3000	1	100
빨강	1500	3	200
파랑	2000	3	300
초록	1500	2	250
보라	6000	1	150


데이터 품질의 중요성



Garbage in Garbage out

머신러닝의 한계





회원 정보

게임 플레이 정보


결제 정보



아이템을 추가해야하나?

컨텐츠 재미가 없나?


...




회원 정보

게임 플레이 정보

결제 정보






회원 정보

게임 플레이 정보

결제 정보



학생들의 시험기간


다른 게임으로 이동

게임 접음



등등

딥러닝?


색깔	꽃길이	가시유무	꽃이름
빨강	10	유	장미
노랑	40	무	해바라기
분홍	15	유	장미
보라	6	무	코스모스
빨강	7	무	tulip
분홍	7	무	코스모스



데이터 크기 작아도 OK



머신러닝 vs 딥러닝



$$\hat{y} = X\hat{w} + b$$

w를 추정해야 하는 상황

머신러닝

$$\hat{w} = (X^T X)^{-1} X^T y$$

딥러닝

1. 처음에 w 를 랜덤 값으로 넣음
2. 예측값 계산
3. 정답과 얼마나 틀렸는지 오차 계산
4. 오차가 줄어드는 방향으로 w 를 조금 수정
5. 수천번 반복

머신러닝 vs 딥러닝

$$e = y - \hat{y}$$

실제값 예측값

error
실제값과 예측값의 차이

머신러닝/딥러닝의 목적 -> error 줄이기

정형 데이터 vs 비정형 데이터

색깔	꽃길이	가시유무	꽃이름
빨강	10	유	장미
노랑	40	무	해바라기
분홍	15	유	장미
보라	6	무	코스모스
빨강	7	무	튤립
분홍	7	무	코스모스

< 정형 데이터 >



이미지



비디오

Aa

텍스트



오디오


< 비정형 데이터 >

AI/BigData 인텐시브 과정

Section 1. 머신러닝 기초개념

Section 1-3. 머신러닝 파이프라인

상의 사이즈 추천 시스템 개발



상의 사이즈 추천 시스템 개발

신발사이즈 x	상의 사이즈 y
245	90
255	105
270	95
280	100
260	100

$$\hat{y} = wx$$

이 값을 추정하는것이 목표
weight

예측 오차 구하기

$$\hat{y} = 0.39x$$

신발사이즈 x	상의 사이즈 y	예측값 $\hat{y}$	손실 $e = y - \hat{y}$
245	90	95	-5
255	105	100	5
270	95	105	-10
280	100	110	-5
260	100	100	0

$$MSE = \frac{1}{n} \sum_{i=1}^5 (y - \hat{y})^2 = \frac{1}{5} ((-5)^2 + 5^2 + (-10)^2 + (-5)^2 + 0^2)$$

$$= \frac{1}{5} (25 + 25 + 100 + 25 + 0) = 35$$

최적화

$$\hat{y} = 0.39x$$

신발 x	상의 y	예측값 $\hat{y}$	손실 $e = y - \hat{y}$
245	90	95	-5
255	105	100	5
270	95	105	-10
280	100	110	-5
260	100	100	0

$$MSE = 35$$

$$\hat{y} = 0.40x$$

신발 x	상의 y	예측값 $\hat{y}$	손실 $e = y - \hat{y}$
245	90	100	-10
255	105	100	5
270	95	110	-15
280	100	110	-5
260	100	105	-5

$$MSE = 86$$


$$\hat{y} = 0.41x$$

신발 x	상의 y	예측값 $\hat{y}$	손실 $e = y - \hat{y}$
245	90	100	-10
255	105	105	0
270	95	110	-15
280	100	115	-15
260	100	105	-5

$$MSE = 127$$

최적화

⋮	⋮
$\hat{w} = 0.39$	$MSE = 35$
$\hat{w} = 0.40$	$MSE = 86$
$\hat{w} = 0.41$	$MSE = 127$
⋮	⋮



상의 사이즈 추천 시스템 개발

신발 사이즈



270

AI
Model

$$\hat{y} = 0.39x$$

```
def ml_model(x):  
    return 0.39*x
```

```
shoes_size = 270
```

```
shirts_size = ml_model(shoes_size)  
print(shirts_size)
```

105.3

상의 사이즈




105

머신러닝 모델 배포

- □ ×

상의 사이즈 추천 시스템





- □ ×

상의 사이즈 추천 시스템





105 사이즈를 추천 드려요 😊

감사합니다.

Q & A