

AI/BigData 인텐시브 과정

강사장철원

Section
코스소개

DAY1

머신러닝
기초 개념

DAY2

지도학습

DAY3

DAY4

서비스
개발

DAY5

앙상블 학습

DAY6

비지도학습

DAY7

시계열분석

DAY8

DAY9

프로젝트

DAY10

□머신러닝의 이해

□데이터 스케일링

□모형 평가

□교차 검증



AI/BigData 인텐시브 과정

Section 1. 모형 평가

Section 1-1. 데이터 스케일링

데이터 스케일링

데이터 단위가 다르면 비교가 어렵다



70 kg

데이터 스케일링

데이터 단위가 다르면 비교가 어렵다

키	몸무게
170	70
175	80
180	90

170 > 70 ?

데이터 스케일링

데이터 스케일링을 하지 않으면 값의 미세한 조정에도 에러가 크게 발산한다.

$$\hat{y} = 0.39x$$

신발 x	상의 y	예측값 $\hat{y}$	손실 $e = y - \hat{y}$
245	90	95	-5
255	105	100	5
270	95	105	-10
280	100	110	-5
260	100	100	0

$$MSE = 35$$

$$\hat{y} = 0.40x$$

신발 x	상의 y	예측값 $\hat{y}$	손실 $e = y - \hat{y}$
245	90	100	-10
255	105	100	5
270	95	110	-15
280	100	110	-5
260	100	105	-5

$$MSE = 86$$

$$\hat{y} = 0.41x$$

신발 x	상의 y	예측값 $\hat{y}$	손실 $e = y - \hat{y}$
245	90	100	-10
255	105	105	0
270	95	110	-15
280	100	115	-15
260	100	105	-5

$$MSE = 127$$

데이터 표준화(standardization)

$$\text{표준화} = \frac{\text{원 데이터} - \text{평균}}{\text{표준편차}}$$



평균 0, 표준편차 1

데이터 표준화(standardization)

키	몸무게
170	70
175	80
180	90

평균 175
표준편차 5

평균 80
표준편차 10

키	몸무게
$\frac{170 - 175}{5} = -1$	$\frac{70 - 80}{10} = -1$
$\frac{175 - 175}{5} = 0$	$\frac{80 - 80}{10} = 0$
$\frac{180 - 175}{5} = 1$	$\frac{90 - 80}{10} = 1$

평균 0
표준편차 1

평균 0
표준편차 1

MinMax 스케일링

$$\text{MinMax 스케일} = \frac{\text{원 데이터} - \min(\text{데이터})}{\max(\text{데이터}) - \min(\text{데이터})}$$



0과 1사이로 데이터 위치

데이터 스케일링

키	몸무게
170	70
175	80
180	90

최대값 180
최소값 170

최대값 90
최소값 70

키	몸무게
$\frac{170-170}{180-170} = 0$	$\frac{70-70}{90-70} = 0$
$\frac{175-170}{180-170} = 0.5$	$\frac{80-70}{90-70} = 0.5$
$\frac{180-170}{180-170} = 1$	$\frac{90-70}{90-70} = 1$

최대값 1
최소값 0

최대값 1
최소값 0

AI/BigData 인텐시브 과정

Section 1. 모형 평가


Section 1-2. 머신러닝 모형 평가

모형 평가




모형이 좋다?/나쁘다?

꽃 분류 모형


주가 예측 모형




환자가 양성인지 음성인지 예측하는 상황



환자가 양성인지 음성인지 예측하는 상황



case 1) 모두 병에 걸렸다고 판정



case 1) 모두 병에 걸렸다고 판정

장점


실제로 병에 걸린
모든 사람들을 치료할 수 있다.

단점

정상인인 사람을 환자로 오인





양성으로 진단(병에 걸렸다고 판정)



음성으로 진단(정상인이라고 판정)



case 2) 모두 음성이라고 판정



case 2) 모두 음성이라고 판정

장점


정상인을 오인하는 경우가 없음

단점


실제 병에 걸린 사람을 치료할 수 없음



양성으로 진단(병에 걸렸다고 판정)



음성으로 진단(정상인이라고 판정)



분류표(confusion matrix)

		예측	
		양성	음성
실제	양성	정답	오답
	음성	오답	정답

분류표(confusion matrix)

		예측	
		양성	음성
실제	양성	True Positive	False Negative Type II Error
	음성	False Positive Type I Error	True Negative

분류표

		예측	
		양성	음성
실제	양성	True Positive TP	False Negative FN
	음성	False Positive FP	True Negative TN

$$\text{정확도(Accuracy)} = \frac{TP + TN}{TP + FP + FN + TN} = \frac{\text{정답 데이터}}{\text{전체 데이터}}$$

$$\text{에러율(Error rate)} = \frac{FP + FN}{TP + FP + FN + TN} = \frac{\text{오답 데이터}}{\text{전체 데이터}}$$

$$\text{민감도(Sensitivity, Recall)} = \frac{TP}{TP + FN} = \frac{\text{예측양성, 실제양성}}{\text{실제 양성}}$$

$$\text{정밀도(Precision)} = \frac{TP}{TP + FP} = \frac{\text{예측양성, 실제양성}}{\text{예측 양성}}$$

$$\text{False Positive Rate} = \frac{FP}{FP + TN} = \frac{\text{예측양성, 실제음성}}{\text{실제 음성}}$$

$$\text{F1-score} = 2 \times \frac{\text{precision} \times \text{recall}}{\text{precision} + \text{recall}}$$

분류표

		예측	
		양성	음성
실제	양성	5 TP	3 FN
	음성	2 FP	10 TN

$$\text{정확도(Accuracy)} = \frac{TP + TN}{TP + FP + FN + TN} = \frac{5+10}{5+2+3+10} = \frac{15}{20} = 0.75$$

$$\text{에러율(Error rate)} = \frac{FP + FN}{TP + FP + FN + TN} = \frac{2+3}{5+2+3+10} = \frac{5}{20} = 0.25$$

$$\text{민감도(Sensitivity, Recall)} = \frac{TP}{TP + FN} = \frac{5}{5+3} = \frac{5}{8} = 0.625$$

$$\text{정밀도(Precision)} = \frac{TP}{TP + FP} = \frac{5}{5+2} = \frac{5}{7} = 0.714$$

$$\text{False Positive Rate} = \frac{FP}{FP + TN} = \frac{2}{10+2} = \frac{2}{12} = 0.167$$

분류표

		예측	
		양성	음성
실제	양성	5 TP	3 FN
	음성	2 FP	10 TN

$$\text{민감도(Sensitivity, Recall)} = \frac{TP}{TP + FN} = \frac{5}{5+3} = \frac{5}{8} = 0.625$$

$$\text{정밀도(Precision)} = \frac{TP}{TP + FP} = \frac{5}{5+2} = \frac{5}{7} = 0.714$$

$$\text{F1-score} = 2 \times \frac{\text{precision} \times \text{recall}}{\text{precision} + \text{recall}} = 2 \times \frac{0.714 \times 0.625}{0.714 + 0.625} = 0.666$$

분류표

		예측	
		양성	음성
실제	양성	1 TP	3 FN
	음성	2 FP	94 TN

$$\text{정확도(Accuracy)} = \frac{TP + TN}{TP + FP + FN + TN} = \frac{1+94}{1+2+3+94} = \frac{95}{100} = 0.95$$

$$\text{민감도(Sensitivity, Recall)} = \frac{TP}{TP + FN} = \frac{1}{1+3} = \frac{1}{4} = 0.25$$

분류표

		예측	
		0	1
실제	0	TN 4	FP 1
	1	FN 2	TP 3

```
y_te = [0, 0, 0, 0, 0, 1, 1, 1, 1, 1]
y_pred = [0, 0, 0, 1, 0, 1, 1, 0, 0, 1]
```

```
# confusion matrix 확인!
from sklearn.metrics import confusion_matrix
conf_matrix = confusion_matrix(y_te, y_pred)
print(conf_matrix)
```

예측
실제

```
[[4 1]
 [2 3]]
```

분류표

		예측	
		0	1
실제	0	TN 4	FP 1
	1	FN 2	TP 3

```
# 정확도(accuracy)
from sklearn.metrics import accuracy_score
accuracy = accuracy_score(y_te, y_pred)
print(accuracy)
```

0.7

```
# 정밀도(precision)
from sklearn.metrics import precision_score
precision = precision_score(y_te, y_pred, average='macro')
print(precision)
```

0.7083333333333333

```
# 리콜
from sklearn.metrics import recall_score
recall = recall_score(y_te, y_pred, average='macro')
print(recall)
```

0.7

```
# F1 스코어
from sklearn.metrics import f1_score
f1 = f1_score(y_te, y_pred, average='macro')
print(f1)
```

0.696969696969697

클래스 1 기준 recall

$$Recall_1 = \frac{TP}{TP + FN} = \frac{3}{3 + 2} = \frac{3}{5} = 0.6$$


클래스 0 기준 recall

$$Recall_0 = \frac{TN}{TN + FP} = \frac{4}{4 + 1} = \frac{4}{5} = 0.8$$


macro recall

$$\begin{aligned} Macro\ Recall &= \frac{Recall_0 + Recall_1}{2} \\ &= \frac{0.6 + 0.8}{2} = \frac{1.4}{2} = 0.7 \end{aligned}$$

ROC Curve



Area Under the Curve(AUC)



```
from sklearn.metrics import roc_auc_score
roc_auc = roc_auc_score(y_te, y_pred)
print(roc_auc)
```

0.7000000000000002

- AUC = ROC 곡선 아래 면적
 - 1: 완벽한 모델
 - 0.5: 동전 던지기 수준
 - <0.5: 동전 던지기 보다 못한 수준

오차 기반 평가

평균 제곱 오차
(Mean Squared Error)

평균

제곱

오차

$$\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$


평균

오차

제곱


오차 기반 평가

실제값 Y_i	예측값 $\hat{Y}_i$
170	171
175	173
180	183



오차 기반 평가

실제값	모형으로 추정한 값
170	171
175	173
180	183



$$\begin{aligned}MSE &= \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 \\&= \frac{1}{3} \times [(170 - 171)^2 + (175 - 173)^2 + (180 - 183)^2] \\&= \frac{1}{3} \times [1^2 + 2^2 + 3^2] = \frac{1}{3} \times (1 + 4 + 9) = \frac{1}{3} \times 14 \\&= 4.67\end{aligned}$$

오차 기반 평가

Mean Squared Error

$$MSE = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

Root Mean Squared Error

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2}$$

Mean Absolute Error

$$MAE = \frac{1}{n} \sum_{i=1}^n |Y_i - \hat{Y}_i|$$

오차 기반 평가

```
y_te = [0.5, 0.6, 0.7, 0.8, 0.9, 1.0, 1.1, 1.2, 1.3, 1.4]
y_pred = [0.4, 0.3, 0.6, 0.9, 1.3, 1.2, 1.4, 0.8, 1.2, 1.3]
```

```
from sklearn.metrics import mean_squared_error
mse = mean_squared_error(y_te, y_pred)
print(mse)
```

```
0.058999999999999998
```

```
from sklearn.metrics import mean_absolute_error
mae = mean_absolute_error(y_te, y_pred)
print(mae)
```

```
0.209999999999999996
```

```
from sklearn.metrics import root_mean_squared_error
rmse = root_mean_squared_error(y_te, y_pred)
print(rmse)
```


```
0.24289915602982234
```

$$MSE = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$


$$MAE = \frac{1}{n} \sum_{i=1}^n |Y_i - \hat{Y}_i|$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2}$$


오버피팅(overfitting)




오버피팅(overfitting)



오버피팅(overfitting)




오버피팅(overfitting)




모형 일반화 적용이 목적




어느 모형이 우수할까




어느 모형이 더 우수할까




어느 모형이 더 우수할까




어느 모형이 더 우수할까




어느 모형이 더 우수할까




언더피팅(underfitting)



언더피팅(underfitting)



언더피팅(underfitting)





AI/BigData 인텐시브 과정

Section 1. 모형 평가

Section 1-3. 교차 검증(cross validation)


Section
교차검증



Section
교차검증


컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험
1회 기출문제	1회 정답	2회 기출문제	2회 정답	3회 기출문제	3회 정답	4회 기출문제	4회 정답	5회 기출문제	5회 정답
컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험
6회 기출문제	6회 정답	7회 기출문제	7회 정답	8회 기출문제	8회 정답	9회 기출문제	9회 정답	10회 기출문제	10회 정답

교차 검증(cross validation)




교차 검증(cross validation)

모델 학습시 사용했던 데이터는 모델 평가에 사용 불가




교차 검증(cross validation)

트레이닝 데이터 / 테스트 데이터 분리




교차 검증(cross validation)

트레이닝 데이터 / 테스트 데이터 분리




교차 검증(cross validation)

트레이닝 데이터 / 밸리데이션 데이터 / 테스트 데이터 분리




교차 검증(cross validation)

트레이닝 데이터 / 밸리데이션 데이터 / 테스트 데이터 분리



k fold cross validation



모델1


모델2

모델3

0.88	0.96	0.92
0.96	1.00	0.96
0.92	0.96	0.96
1.00	0.96	0.96
0.84	1.00	1.00

평균	0.92	0.97	0.96
----	------	------	------

교차 검증(cross validation)



AI/BigData 인텐시브 과정


Section 2. 머신러닝의 이해

Section 2-1. 머신러닝 파이프라인


데이터 전처리

[illegible]


원 핫 인코딩 etc

[illegible]

피처 / 타겟 분리

[illegible][illegible]

트레이닝 / 테스트 데이터 분할

[illegible][illegible]

트레이닝 데이터


[illegible]테스트
데이터

x1	x2	x3_1	x3_2	x3_3

[illegible]

y


데이터 스케일링





학습

트레이닝
데이터

x1	x2	x3_1	x3_2	x3_3	y



평가




데이터 준비

- □ ×

상의 사이즈 추천 시스템





- □ ×

상의 사이즈 추천 시스템





105 사이즈를 추천 드려요 😊

감사합니다.

Q & A